LABORATUVAR 7 · PAKETPRO 3000 · Paketleme Makinesi

AI Safety Challenge

Çıktı: AI Fail-Safe Decision

CEVAPLANAN MAKİNE: AYSPAK-TF30 | Öğrenci no: 235541088

Ad Soyad	Grup	Tarih
Emin Çimen	Belirtilmedi	06.11.2026

Kavram — Prediction ≠ Safety: Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin **dışında** tanımlanmalıdır.
Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

*Senaryo: PaketPro'ya YZ'li görsel paket kontrolü **eklenmesi planlanıyor** — proje aşaması değerlendirmesi yapıyorsunuz.*

Kamera → YZ Modeli → OK / RED → Ret mekanizması → Hat hızı

Görev — üç başarısızlıkta güvenli davranış

1. **Model yanlış sınıflandırdı:** Kusurlu parçaya OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?

   TF30 çıkışında biçim/kıvrım ve görünür tutkal kusuru kontrolü önerilir; YZ'nin kendi hatasını fark edeceği varsayılmaz. Ayrı ikinci kontrol ve insan denetimi; şüpheli partiyi karantinaya al. Ret doğrulanamazsa kontrollü duruş. Kavram: monitoring, human override, fallback.

2. **Girdi manipüle edildi:** Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?

   Kare zamanı/sırası, donmuş görüntü, odak/ışık, kaynak kimliği ve model bütünlüğü izlenir. Şüpheli girdide TF30 kutusuna otomatik OK verilmez; karantina ve inceleme. Ayırma mümkün değilse kontrollü duruş. Kavram: monitoring, fail-safe, fallback.

3. **Confidence düştü:** Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?

   TF30 için 0,95 yalnız önerilen eğitim başlangıcıdır; eşik temsilî kusur verisiyle doğrulanır. Altında veya çelişkide otomatik OK yok: karantina/insan incelemesi; kuyruk dolu veya ret başarısızsa duruş. Yüksek skor doğruluk ya da emniyet garantisi değildir.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	Ayrı ikinci kontrol + insan denetimi; karantina. Monitoring / human override / fallback.
Girdi manipüle edildi	Girdi sağlığı ve kaynak denetimi; otomatik OK yok. Karantina veya duruş. Fail-safe / monitoring.
Confidence düştü	0,95 yalnız eğitim önerisi; belirsizlikte karantina/insan; işlenemiyorsa duruş. Threshold / fallback.

Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.

TF30'da kalite kararı ile insan emniyetinin sınırı

Kamera/YZ ve ret düzeneği TF30'a önerilen projedir; mevcut donanım değildir. Görsel muayene tek başına yapışma dayanımını kanıtlamaz.

Kabul koşulu: Girdi geçerli + OK skoru en az 0,95 + ayrı kontrol uygun. Kusur, çelişki veya geçersiz görüntüde otomatik kabul yoktur. Gerçek eşik yanlış kabul/ret verisiyle seçilir.

YZ, kapak/acil durdurmayı bypass edemez, emniyet resetini veya güvenli parametreleri değiştiremez. SF-01–SF-04, YZ arızasında da bağımsız kalmalıdır. İnsan kaliteyi değerlendirebilir; emniyet kilidini aşamaz.

Planlanan doğrulama: Temsilî kusur veri seti, yanlış kabul/ret oranı, eşik ve model sürümü, bozuk/donmuş görüntü, ret geri bildirimi ve kuyruk dolma. Model eğitilmemiş, test yapılmamıştır.

TF30 için eğitim senaryosu; gerçek zafiyet, olay veya YZ sistemi tespiti değildir. Saha testi yapılmamıştır.
Kaynak: Ders föyü ve ilgili resmî rehber; ayrıntılı cevaplar / kaynak bağlantıları bu klasörün README.md dosyasındadır.